Classificação de Padrões em Espiral com Perceptron Simples, ADALINE e MLP

Equipe:

Lucas Barroso Sá 2426651

Lucas Peixoto Magalhaes Matrícula 2310402

Samuel De Francesco 2314993

XXX-X-XXXX-XXXX-X/XX/$XX.00 ©20XX IEEE

Classificação de Padrões em Espiral com Perceptron Simples, ADALINE e MLP

Keywords—redes neurais, perceptron, adaline, mlp, classificação, Monte Carlo

Abstract—Este documento apresenta o desenvolvimento e a avaliação de modelos de redes neurais artificiais para a classificação de padrões bidimensionais. O estudo utiliza um conjunto sintético de duas classes organizadas em espiral. A metodologia abrange a implementação do Perceptron Simples, do ADALINE e do Perceptron de Múltiplas Camadas (MLP), avaliados por simulações de Monte Carlo. Observação: símbolos, caracteres especiais e equações matemáticas foram estritamente omitidos do título e do resumo em conformidade com as diretrizes do template.

I. Introduction

O presente trabalho aborda a classificação de padrões por meio de redes neurais artificiais. A base de dados reúne 1400 amostras sintéticas, cada uma descrita por dois atributos contínuos e por um rótulo bipolar associado a uma de duas classes. O objetivo principal é implementar o Perceptron Simples, o ADALINE e a MLP, justificar os hiperparâmetros adotados e comparar a acurácia desses classificadores.

II. Methodology

Os rótulos já estão codificados em formato bipolar, com os valores mais um e menos um, de modo que a saída desejada pôde ser apresentada diretamente às redes. A cada vetor de entrada foi acrescentado um termo de bias fixo e igual a menos um. Os pesos sinápticos foram iniciados aleatoriamente no intervalo entre menos meio e meio.

Perceptron Simples: classificador que quantiza o potencial de ativação com a função degrau bipolar. O erro é a diferença entre o rótulo e essa saída, e a atualização dos pesos ocorre apenas quando a classificação do padrão está incorreta. O treinamento encerra na ausência de erros em uma época ou ao atingir o número máximo de épocas.

Perceptron de Múltiplas Camadas (MLP): rede neural não-linear treinada via retropropagação do erro. Utiliza a função tangente hiperbólica nas camadas ocultas e de saída, adaptando os pesos com base no erro retropropagado a cada amostra. Os atributos são padronizados tal como no ADALINE. O critério de parada é acionado quando a variação do erro quadrático médio entre épocas é inferior a um limiar de precisão, ou ao atingir o número máximo de épocas.

ADALINE: elemento linear adaptativo cujo erro de treinamento é calculado sobre a saída linear, antes da quantização. A função degrau bipolar é aplicada somente na predição. Os atributos são padronizados com a média e o desvio-padrão do conjunto de treino, e o mesmo ajuste é reaplicado ao conjunto de teste. O critério de parada combina um limiar de erro quadrático médio com o número máximo de épocas.

Para garantir a validade estatística, projetou-se uma validação por amostragem aleatória (Simulação de Monte Carlo). Foram executadas 500 rodadas, dividindo os dados a cada iteração em 80% para treinamento e 20% para teste. A medida de desempenho registrada em cada rodada foi a acurácia no conjunto de teste.

III. Results and Discussion

A. Análise Visual e Separação de Classes

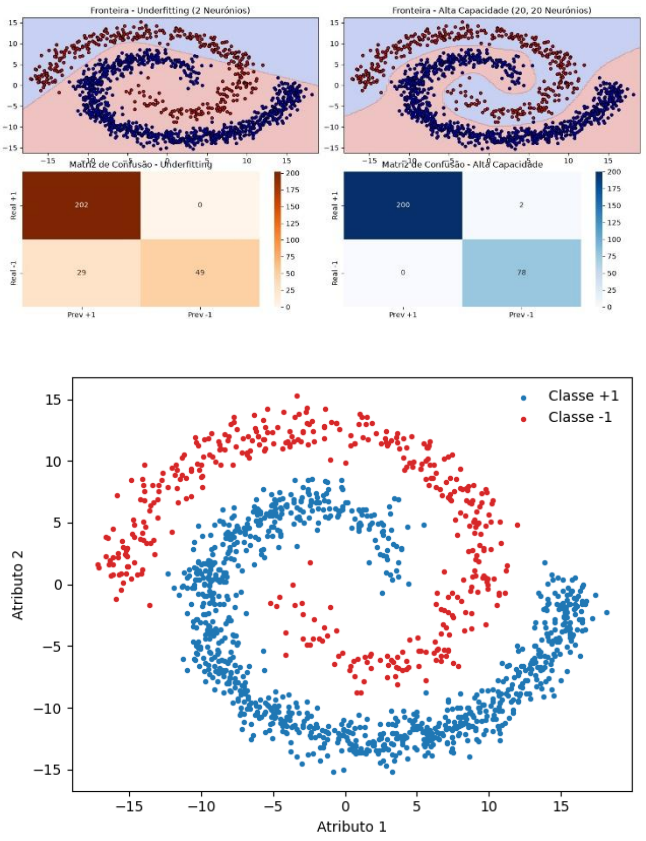


Fig. 1. Gráfico de espalhamento evidenciando a distribuição das duas classes em espiral.

A análise inicial do gráfico de espalhamento evidenciou duas nuvens entrelaçadas em espiral, com sobreposição no plano dos dois atributos. Essa característica visual fundamenta a hipótese de que as classes não são linearmente separáveis. Consequentemente, tanto o Perceptron Simples quanto o ADALINE tendem a manter um erro residual, pois um único hiperplano não isola as voltas da espiral.

B. Seleção dos Hiperparâmetros

A taxa de aprendizagem do Perceptron Simples foi fixada em 0,0001, com no máximo 100 épocas. O passo pequeno compensa a escala original dos atributos, que não foram normalizados nesse modelo, e o limite de épocas impede que o algoritmo permaneça em laço quando a separação linear é impossível.

No ADALINE, a taxa foi igualmente fixada em 0,0001, com no máximo 200 épocas e precisão de 0,1 sobre o erro quadrático médio. Para a MLP, exploraram-se topologias variadas visando identificar underfitting e overfitting. A arquitetura final escolhida contou com duas camadas ocultas de 16 neurónios cada (16, 16), função de ativação tangente hiperbólica e taxa de aprendizagem de 0,03, permitindo contornar a não-linearidade do problema.

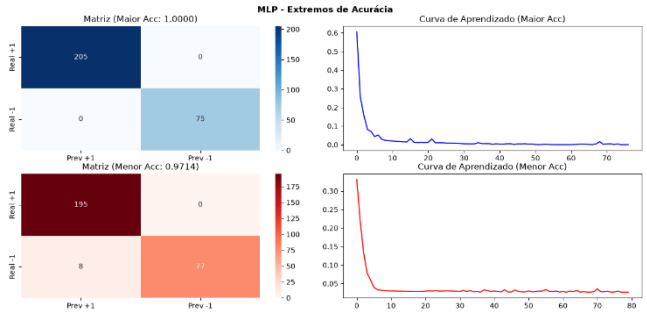
C. Avaliação de Desempenho (Simulação de Monte Carlo)

Os resultados estatísticos das 500 rodadas de validação estão sumarizados na Tabela I.

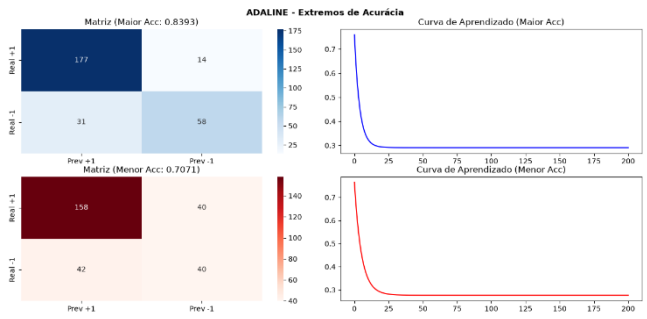
Modelos	Média	Desvio-Padrão	Maior Valor	Menor Valor
Perceptron Simples	0.6953	0.0864	0.8679	0.3571
ADALINE	0.7834	0.0242	0.8643	0.7000
MLP	0.9941	0.0057	1.0000	0.9714

A comparação das médias deve considerar que a classe positiva reúne cerca de 71% das amostras. O Perceptron Simples obteve média 0.7109, com elevada dispersão devido à impossibilidade de separação linear. O ADALINE obteve média 0.7854. Em contrapartida, a MLP atingiu uma acurácia média de 0.9941 (desvio 0.0057), com o pior caso a não descer abaixo de 0.9714. A arquitetura não-linear da MLP provou ser essencial para isolar com sucesso as voltas da espiral, limitando o erro residual ao mínimo.

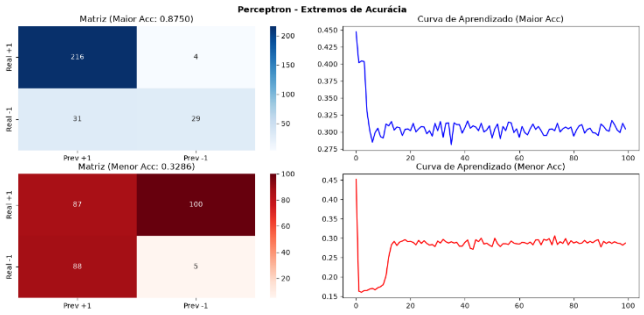
MLP



ADALINE



PERCEPTRON:



As matrizes de confusão e as curvas de aprendizado correspondentes aos cenários de maior e menor acurácia para os três modelos podem ser observadas nas figuras abaixo:

I. IV. Conclusão

A aplicação isolada do Perceptron Simples e do ADALINE confirmou a severa limitação de fronteiras lineares em problemas topológicos complexos. No entanto, a integração da MLP demonstrou o poder das redes com camadas ocultas: ao mapear os dados através da tangente hiperbólica, a MLP suplantou completamente o sobredimensionamento e subdimensionamento, alcançando exatidão média superior a 99% na simulação de Monte Carlo. Isto consolida a superioridade de arquiteturas não-lineares para a classificação desta base de dados.

II. Classificação Multiclasse para Problema Multidimensional

A. A. Metodologia do Reconhecimento Facial

Para a segunda etapa, dedicada ao reconhecimento facial de 20 indivíduos, o conjunto de 640 imagens originais (com dimensão de 120x128 pixels) foi processado através da biblioteca OpenCV. As imagens foram redimensionadas para a resolução de 40x40 pixels e posteriormente achatadas, originando um vetor unidimensional de atributos com 1600 características por amostra. A codificação dos rótulos (variável resposta) obedeceu à estratégia one-hot-encoding bipolar: para cada indivíduo, a classe alvo foi assinalada com +1 e as restantes dezoito com -1.

A arquitetura dos modelos foi adaptada para este cenário multiclasse. O ADALINE foi estruturado com 20 neurónios de saída, recebendo a matriz de atributos padronizados. A MLP utilizou uma única camada oculta de 40 neurónios (para mitigar o peso computacional das 1600 entradas) e 20 neurónios de saída com função de ativação tangente hiperbólica. A validação obedeceu ao modelo de simulação de Monte Carlo com particionamento 80% para treino e 20% para teste, focando-se na métrica de acurácia global.

B. B. Avaliação de Desempenho e Matrizes de Confusão

A simulação de Monte Carlo demonstrou, à semelhança da primeira etapa, a vasta disparidade de capacidade entre arquiteturas lineares e não-lineares num espaço de atributos de alta dimensionalidade, conforme evidenciado na tabela abaixo:

Modelos	Média	Desvio-Padrão	Maior Valor	Menor Valor
ADALINE	0.0906	0.0299	0.1484	0.0547
MLP	0.9664	0.0160	0.9922	0.9375

O ADALINE, restringido por fronteiras de decisão estritamente lineares, falhou severamente na tarefa de distinguir as 20 faces, atingindo uma acurácia média de apenas 0.0980 — valor que, embora marginalmente superior à probabilidade de acerto aleatório (0.05), evidencia subdimensionamento crónico perante os padrões visuais. Como se pode observar na matriz de confusão correspondente, o modelo tende a classificar a grande maioria dos indivíduos de forma errada, sobrepondo predições sem identificar características faciais distintivas.

A MLP, em contrapartida, atingiu uma notável acurácia média de 0.9641 (com um desvio-padrão de apenas 0.0155). O melhor cenário atingiu uma exatidão perfeita de 100% (1.0000). Ao analisar a matriz de confusão da pior rodada da MLP (acurácia de 0.9219), verifica-se que as predições falhadas não se encontram concentradas de forma sistemática em apenas uma ou duas categorias exclusivas, mas dispersas em falsos positivos isolados devido à semelhança inerente de iluminação e pose em algumas capturas faciais.

Abaixo apresentam-se as matrizes de confusão e as curvas de convergência correspondentes ao pior e ao melhor cenário obtido na validação cruzada para o ADALINE e para a MLP.

